


¿Qué es Natural Language Processing (NLP/PNL)?



Clasificación de texto




Clasificación de texto




Clasificación de texto




Clasificación de texto




Clasificación de texto



Clasificación de texto




Generación de Texto

 **GPT-Neo & Hugging Face Accelerated Inference API**

Here you can use your [API token](#) to run Few-Shot examples using [GPT-Neo](#) from [EleutherAI](#).
If you don't have an account you can get started [here](#).

API Token

Task

Write your own prompt 

End Sequence **Token Length** **Temperature**

75 1

Example prompt:


Hoy es un buen día

Generate

The GPT-neo system is a large language model trained on The Pile dataset, a large text corpus that is extensively documented in [Gao et al., 2021](#). As such, it is expected to function better on text that matches the distribution of its training text; we recommend keeping this in mind when designing systems that rely on its output and in considering how the system might impact different groups of users. For further discussion on these questions, we refer you to e.g. [Bender et al., 2021](#).



Generación de Texto

 **GPT-Neo & Hugging Face Accelerated Inference API**

Here you can use your [API token](#) to run Few-Shot examples using [GPT-Neo](#) from [EleutherAI](#).
If you don't have an account you can get started [here](#).

API Token

Task

Write your own prompt

End Sequence **Token Length** **Temperature**

Example prompt:

Hoy es un buen día

Generate

The GPT-neo system is a large language model trained on The Pile dataset, a large text corpus that is extensively documented in [\(Gao et al., 2021\)](#). As such, it is expected to function better on text that matches the distribution of its training text; we recommend keeping this in mind when designing systems that rely on its output and in considering how the system might impact different groups of users. For further discussion on these questions, we refer you to e.g. [\(Bender et al., 2021\)](#)

Example prompt:

Hoy es un buen día en San Juan, la capital del estado de Puerto Rico, donde las calles se han convertido en una de las tres grandes avenidas del mundo. El sábado, cuatro mil habitantes abandonan la ciudad, para irse a la isla de Navidad, a la cual el president



Y otros dominios



wav2vec: audio to text



Y otros dominios



wav2vec: audio to text




DALLE: text to image

TEXT PROMPT

an armchair in the shape of an avocado. . . .

AI-GENERATED
IMAGES



Edit prompt or view more images ↴



Word Embeddings



Hay


un

león


corriendo



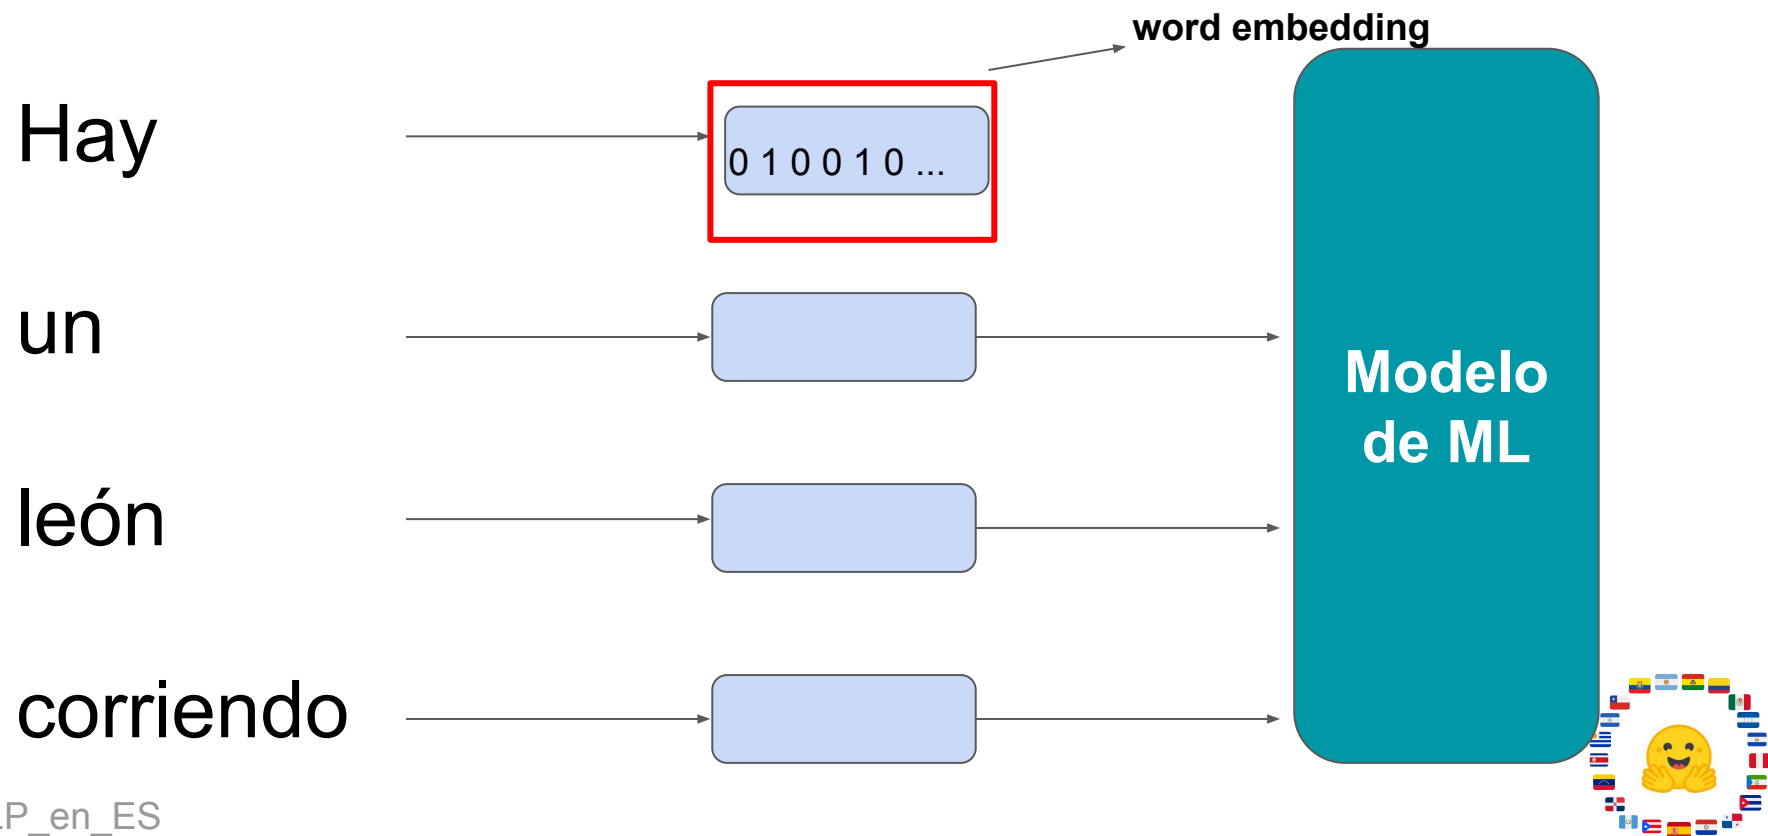
Los word embeddings son representaciones del texto




Los word embeddings son representaciones del texto




Los word embeddings son representaciones del texto



Se tiene una tabla que mapea cada palabra del vocabulario a la posición de su word embedding.



10000 word
embeddings



0 1 0 0 0 0 0 ...

representación de una palabra

256 números por palabra



Incendio

	león
	gato
	hay
	parque
	sol
	fuego
	río
	UNK



El caracter especial UNK se suele utilizar para palabras fuera del vocabulario (out-of-vocabulary)

~~Incendio~~

UNK

	león
	gato
	hay
	parque
	sol
	fuego
	río
	UNK



Vocabulario: Hola, Sol, Playa



One-hot Encoding

Sol [0, 1, 0, 0]

Playa [0, 0, 1, 0]

Hola [1, 0, 0, 0]

Feliz [0, 0, 0, 1]

Vocabulario: Hola, Sol, Playa



One-hot Encoding: Este es un ejemplo en el que el vocabulario sólo tiene las palabras de la oración, pero el vocabulario suele ser mucho más grande.

Ejemplo: Hoy es un buen día

```
[  
  [0, 0, 0, 0,..., 1, 0],  
  [1, 0, 0, ,...,0, 0, 0],  
  [0,..., 1, 0, 0, 0, 0],  
  [0, 0, 1, 0, ...,0, 0],  
  [0, 0, 0, 1, 0, ...,0]  
]
```



One-hot Encoding: Este es un ejemplo en el que el vocabulario sólo tiene las palabras de la oración, pero el vocabulario suele ser mucho más grande.

Ejemplo: Hoy es un buen día

```
[  
  [0, 0, 0, 0, 1, 0],  
  [1, 0, 0, 0, 0, 0],  
  [0, 1, 0, 0, 0, 0],  
  [0, 0, 1, 0, 0, 0],  
  [0, 0, 0, 1, 0, 0]  
]
```



¿Saben que es una **pachamanca**?



¿Saben que es una **pachamanca**?

El plato de **pachamanca** en la mesa.

Es demasiada **pachamanca** para mí

La **pachamanca** es típica en los Andes.



¿Saben que es una **pachamanca**?

El plato de **pachamanca** en la mesa.

Es demasiada **pachamanca** para mí

La **pachamanca** es típica en los Andes.



¿Saben que es una **pachamanca**?

El plato de **pachamanca** en la mesa.

Es demasiada **pachamanca** para mí

La **pachamanca** es típica en los Andes.

Contexto



¿Cómo supieron?

- Aunque nunca habían visto esa palabra antes, sí habían visto palabras en contextos similares.

El plato de **arroz** en la mesa.

Es demasiada **hamburguesa** para mí

La **quinoa** es típica en los Andes.



¿Cómo ponemos información de estos contextos en nuestras representaciones?

- Co-ocurrencias usando una ventana
- Información Mutua Puntual (PPMI)
- Y muchos métodos más



Word2vec

... Hoy es un gran día ...



Word2vec

... **Hoy** **creo** **es** **un** **gran** día para ...



Ventana de 5



Word2vec

... Hoy **creo es un gran día** para ...



Ventana de 5



Variantes de Word2vec

- Skip-Gram: predice el contexto dada una palabra central
- Continuous Bag of Words (CBOW): predice la palabra central sumando los vectores de contexto



¿Cómo sabemos si el word embedding es bueno?

- Dadas las métricas al entrenarlo.
- Utilizándolo para entrenar un modelo en una tarea (por ejemplo, clasificación)



Propiedades - estructura linear

- Relaciones semánticas y sintácticas son lineares en el espacio vectorial

$V(\text{rey}) - V(\text{hombre}) + V(\text{mujer}) = V(\text{reina})$



$V(\text{reyes}) - v(\text{rey}) + V(\text{reina}) = V(\text{reinas})$

$V(\text{España}) - V(\text{Madrid}) + V(\text{Paris}) = V(\text{Francia})$

$V(\text{fuego}) - V(\text{caliente}) + V(\text{frío}) = V(\text{hielo})$

semantic: $v(\text{king}) - v(\text{man}) + v(\text{woman}) \approx v(\text{queen})$

syntactic: $v(\text{kings}) - v(\text{king}) + v(\text{queen}) \approx v(\text{queens})$



https://lena-voita.github.io/nlp_course/word_embeddings.html



Sesgos

Extreme *she* occupations

- | | | |
|-----------------|-----------------------|------------------------|
| 1. homemaker | 2. nurse | 3. receptionist |
| 4. librarian | 5. socialite | 6. hairdresser |
| 7. nanny | 8. bookkeeper | 9. stylist |
| 10. housekeeper | 11. interior designer | 12. guidance counselor |

Extreme *he* occupations

- | | | |
|----------------|-------------------|----------------|
| 1. maestro | 2. skipper | 3. protege |
| 4. philosopher | 5. captain | 6. architect |
| 7. financier | 8. warrior | 9. broadcaster |
| 10. magician | 11. fighter pilot | 12. boss |

Man is to Computer Programmer as Woman is to Homemaker? Debiasing Word Embeddings (2016), Bolukbasi et. al.



Enlaces útiles



[@nlp-en-es/nlp-de-cero-a-cien](#)



#nlp-de-cero-a-cien



[@nlp en es](#)



[@company/nlp-en-es/](#)

